Curso **ANÁLISE E DESENVOLVIMENTO DE SISTEMAS**	Disciplina **INTELIGÊNCIA ARTIFICIAL E MACHINE LEARNING**
Professor **LUCY MARI**	Data **10/11/2025**

PROJETO INTERDISCIPLINAR – CANNOLI

Integrantes:

Anderson Yavi Fernandez - RA: 24025678

Gabriel Gonçalves Pires - RA: 24026518

Isabela Nunes Zeferino - RA: 24026460

Kaique Neres de Oliveira - RA: 24026134

Luiz Felipe Galdino de Carvalho - RA: 2402656

1. Introdução e Objetivo

O principal desafio de marketing da Cannoli é a falta de personalização, pois a base de clientes não é segmentada. Isso leva a campanhas de marketing genéricas e pouco eficientes. O objetivo deste trabalho foi aplicar um modelo de Machine Learning para resolver esse problema, agrupando os clientes em perfis distintos com base no seu comportamento de compra. A ideia é criar segmentos que permitam à Cannoli desenvolver estratégias de marketing mais inteligentes e direcionadas.

2. Aplicação do Modelo

O processo foi dividido em três etapas principais, executadas em um notebook Colab.

2.1. Etapa 1: Preparação dos Dados (RFM)

O primeiro passo foi preparar os dados para o modelo. Carregamos o arquivo de pedidos (Order_semicolon.csv), limpamos as datas e, a partir daí, calculamos três métricas essenciais para cada cliente, um processo conhecido como **Análise RFM**:

- **Recência (R):** Há quantos dias foi a última compra.
- **Frequência (F):** O número total de vezes que o cliente já comprou.
- **Monetário (M):** O valor total que o cliente já gastou.

```
import pandas as pd
from sklearn.cluster import KMeans
from sklearn.preprocessing import StandardScaler
import matplotlib.pyplot as plt
# 1. Carregar e Limpar os Dados
print("Carregando e limpando os dados de pedidos...") df_order
= pd.read_csv('Order_semicolon.csv', sep=';')
df_order['createdAt']      =
     pd.to_datetime(df_order['createdAt'], dayfirst=True,
errors='coerce')
df_order = df_order.dropna(subset=['createdAt']) print("...dados
carregados e limpos.")

# 2. Calcular e Normalizar as Métricas RFM
print("\nCalculando e normalizando as métricas RFM...")
data_maxima = df_order['createdAt'].max() + pd.to_timedelta('1D')

rfm_df = df_order.groupby('customer').agg(
    Recencia=('createdAt',    lambda    date:    (data_maxima    -
date.max()).days),
    Frequencia=('id', 'count'),
    Monetario=('totalAmount', 'sum')
).reset_index()

rfm_features = rfm_df[['Recencia', 'Frequencia', 'Monetario']]
scaler = StandardScaler()
rfm_scaled = scaler.fit_transform(rfm_features)
print("...métricas RFM prontas para o modelo.")
```

2.2. Etapa 2: Definição e Aplicação do Modelo (K-Means)

Com os dados preparados, usamos a técnica "Método do Cotovelo" para decidir em quantos grupos (clusters) iríamos dividir os clientes. O gráfico resultante indicou que **4** era um bom número. Em seguida, aplicamos o algoritmo de Machine Learning **K-Means** para agrupar os clientes.

```
# 3. Rodando o Método do Cotovelo (Elbow Method) para achar o melhor
numero de grupos
print("\nRodando o Método do Cotovelo para achar 'k'...")
inertia = [] K = range(1, 11) for k in K:     kmeans =
KMeans(n_clusters=k, random_state=42, n_init=10)
kmeans.fit(rfm_scaled)
    inertia.append(kmeans.inertia_)

# Plotando o grafico para a gente visualizar o "cotovelo"
plt.figure(figsize=(8, 5)) plt.plot(K, inertia, 'bx-')
plt.xlabel('Número de Clusters (k)')
plt.ylabel('Inertia')
plt.title('Método do Cotovelo para K-Means') plt.show()
```

Resultado do Método do Cotovelo:

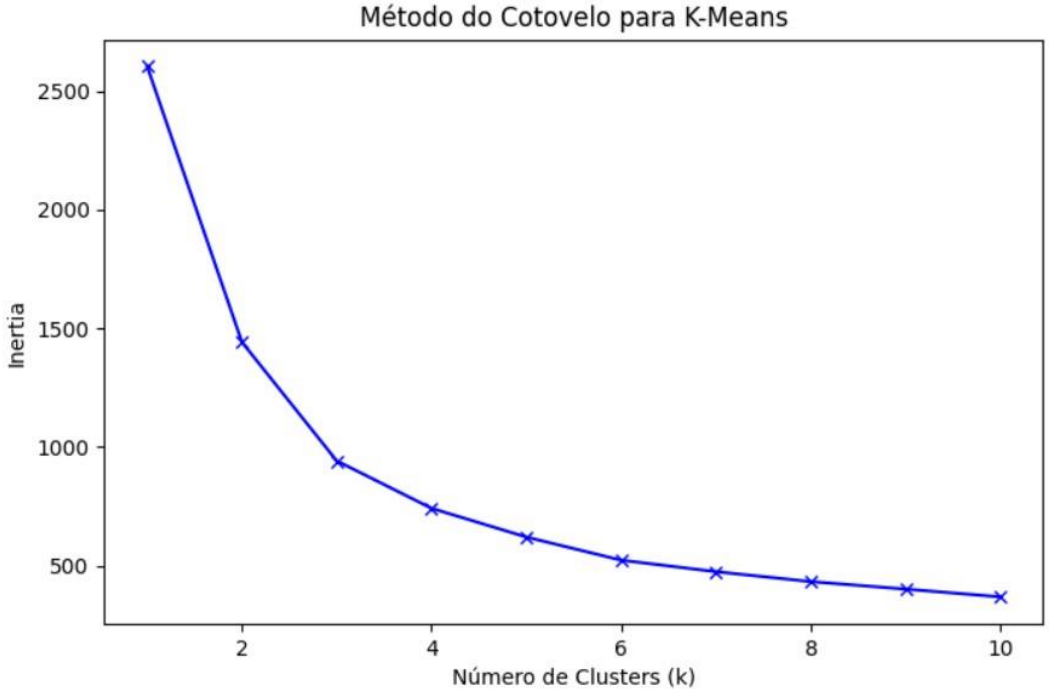

2.3. Etapa 3: Análise e Interpretação dos Resultados

Esta é a etapa final, onde pegamos os grupos que o modelo criou e os traduzimos para o negócio, dando um "apelido" (persona) para cada um deles.

```
# 4. Aplicando o K-Means e nomeando os segmentos print("\nAplicando
o modelo K-Means com k=4...")
```

```
kmeans_final = KMeans(n_clusters=4, random_state=42, n_init=10)
kmeans_final.fit(rfm_scaled) rfm_df['Cluster'] =
kmeans_final.labels_
print("...modelo aplicado! Clientes foram agrupados.")

# Interpretando e dando nome aos grupos
print("\nAnalisando e nomeando os segmentos encontrados...")
analise_clusters     =     rfm_df.groupby('Cluster')[['Recencia',
'Frequencia', 'Monetario']].mean().reset_index()

# Usando um sistema de ranking pra nomear os grupos automaticamente
analise_clusters['rank_recencia'] =
analise_clusters['Recencia'].rank(ascending=True)
analise_clusters['rank_frequencia']                                    =
analise_clusters['Frequencia'].rank(ascending=False)
analise_clusters['rank_monetario']                                     =
analise_clusters['Monetario'].rank(ascending=False)
analise_clusters['pontuacao_geral']                                     =
analise_clusters['rank_recencia']                                      +
analise_clusters['rank_frequencia'] +
analise_clusters['rank_monetario']
analise_clusters = analise_clusters.sort_values('pontuacao_geral')

nomes_segmentos = ['Clientes Campeões', 'Clientes Leais', 'Clientes
Novos/Promissores', 'Clientes em Risco']
analise_clusters['Segmento']                                           =
nomes_segmentos[:len(analise_clusters)] print("...segmentos nomeados
com sucesso!")

# Exibindo o resultado final de negocio
print("\n\n--- RESULTADO FINAL: Resumo dos Segmentos de Clientes --
-")
display(analise_clusters[['Segmento', 'Recencia', 'Frequencia',
'Monetario']])
```

Tabela de Resumo dos Segmentos:

```
--- RESULTADO FINAL: Resumo dos Segmentos de Clientes ---
```

	Segmento	Recencia	Frequencia	Monetario
3	Clientes Campeões	54.304348	4.673913	314.200000
0	Clientes Leais	89.773585	3.041509	182.892113
2	Clientes Novos/Promissores	71.854610	1.542553	82.622872
1	Clientes em Risco	257.921397	1.436681	82.419432

3. Conclusão

A aplicação do modelo K-Means foi bem-sucedida em segmentar a base de clientes em quatro grupos acionáveis: **Clientes Campeões, Clientes Leais, Clientes Novos/Promissores e Clientes em Risco**.

O projeto cumpre o objetivo de aplicar um modelo de ML a um problema de negócio real, transformando dados brutos em inteligência para o direcionamento de campanhas de marketing e otimização de recursos. Com essa segmentação, a Cannoli pode agora criar campanhas muito mais eficientes, como uma oferta de reativação para os "Clientes em Risco".